Assignment #1 Report
Adversarial Attacks on MNIST and CIFAR-10

2021550014 Jongseok Seo

March 31, 2026

1 Introduction

이번 과제에서는 이미지 분류기에 대해 네 가지 Adversarial Attack 방법을 구현하였다: targeted FGSM, untargeted FGSM, targeted PGD, untargeted PGD. 실험은 MNIST와 CIFAR-10 두 데이터셋에서 진행했다. 주요 목표는 섭동 크기 ϵ에 따른 공격 성공률을 비교하고, 공격 유형과 섭동 크기가 성능에 미치는 영향을 분석하는 것이다.

2 Clean Accuracy

Adversarial Attack을 수행하기 전에 각 분류기의 정상 데이터 테스트 정확도를 먼저 확인했다. 기본 분류기가 정상 데이터에서 충분한 성능을 보여야 공격 결과를 의미 있게 해석할 수 있기 때문이다. 이를 위해 직접 모델 학습을 수행하였으며, MNIST 분류기의 정상 테스트 정확도는 **98.85%**였다. CIFAR-10 분류기의 정상 테스트 정확도는 **85.24%**였다. 이 값들은 과제 권장 기준에 대체로 부합하며, 공격 실험 결과를 해석하기에 충분한 수준이다.

3 Attack Success Rates

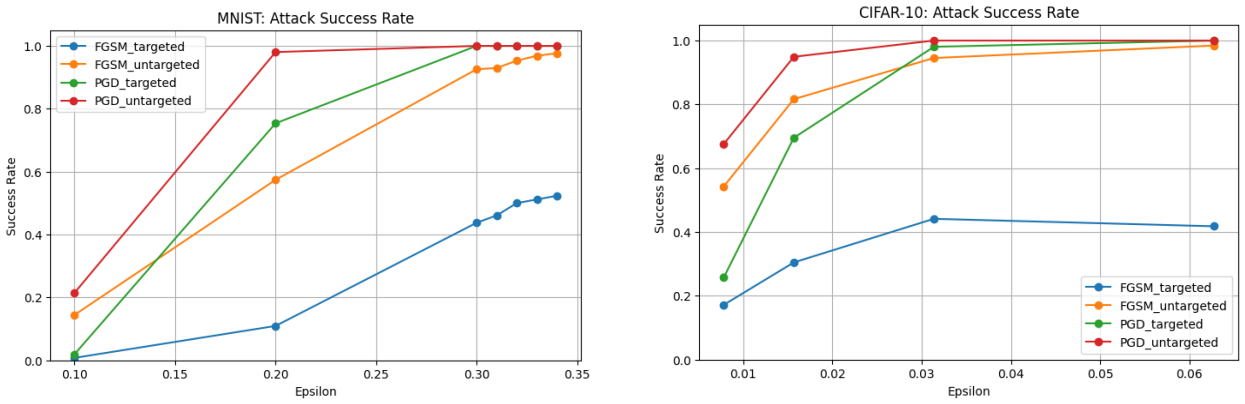

Figure 1: MNIST와 CIFAR-10에서 ϵ에 따른 공격 성공률

ϵ값은 데이터셋의 특성을 고려하여 다르게 설정하였다. MNIST는 흑백의 단순한 숫자 이미지이기 때문에 상대적으로 큰 perturbation budget에서도 공격 양상을 관찰하기 적절하다고 판단하여 0.1 ∼ 0.34 범위의 값을 사용하였다. 반면 CIFAR-10은 컬러 자연 이미지로 구성되어 있어 같은 크기의

perturbation이 시각적으로 훨씬 크게 나타날 수 있으므로, 보다 현실적이고 일반적인 설정에 맞추어 1/255 스케일로 더 작은 ϵ 값을 사용하였다. 또한 위 성공률은 모두 256개의 샘플에 대해 측정된 값이다.

Table 1: MNIST 공격 성공률

ϵ	FGSM Targeted	FGSM Untargeted	PGD Targeted	PGD Untargeted
0.1	0.0078	0.1445	0.0195	0.2148
0.2	0.1094	0.5742	0.7539	0.9805
0.3	0.4375	0.9258	1.0000	1.0000
0.31	0.4609	0.9297	1.0000	1.0000
0.32	0.5000	0.9531	1.0000	1.0000
0.33	0.5117	0.9688	1.0000	1.0000
0.34	0.5234	0.9766	1.0000	1.0000

Table 2: CIFAR-10 공격 성공률

ϵ	FGSM Targeted	FGSM Untargeted	PGD Targeted	PGD Untargeted
2/255	0.1719	0.5430	0.2578	0.6758
4/255	0.3047	0.8164	0.6953	0.9492
8/255	0.4414	0.9453	0.9805	1.0000
16/255	0.4180	0.9844	1.0000	1.0000

4 Discussion

우선 두 데이터셋에서 일관된 경향이 관찰되었다.

ϵ이 증가할수록 두 데이터셋에서 대부분의 공격 방법의 성공률이 증가했는데, 이는 더 큰 perturbation이 결정 경계를 더 쉽게 넘게 만들기 때문으로 생각된다. 또한 untargeted 공격은 특정 클래스로 유도해야 하는 targeted 공격보다 일반적으로 더 쉽기에 전반적으로 Untargeted 계열이 성공률이 더 높다는 것을 관찰할 수 있었다. 이때 PGD는 같은 ϵ 제약에서 반복적 업데이트를 사용하므로 FGSM 보다 일관되게 강한 성능을 보였다.

다만 실험 결과 중 CIFAR-10 데이터셋에서 FGSM Targeted는 $\epsilon = 16/255$ 구간에서 오히려 성공률이 소폭 감소하는 모습을 보였다. FGSM Untargeted와 비교했을 때 다소 이례적인 결과이다. 이러한 현상은 targeted attack의 경우 단순히 오분류를 유도하는 것이 아니라 특정 target class로 예측을 이동시켜야 하기 때문에, perturbation의 크기가 커진다고 해서 항상 성공률이 단조롭게 증가하지는 않을 수 있음을 시사한다. 특히 FGSM은 단일 step 공격이므로, 큰 perturbation이 오히려 target 방향에 비효율적으로 작용했을 가능성도 있다.

MNIST(98.85%)와 CIFAR-10(85.24%)의 정상 정확도를 고려하면 결과는 신뢰할 만하며, ϵ이 커질수록 공격 성공률은 올라가지만 시각적 왜곡도 함께 커지는 trade-off를 확인할 수 있다.

5 Conclusion

실험 결과, ϵ이 증가할수록 Adversarial Attack은 대체로 강해졌고, 전반적으로 PGD가 FGSM보다 강했으며, untargeted 공격이 targeted 공격보다 성공하기 쉬웠다. 이 경향은 MNIST와 CIFAR-10에서 모두 일관되게 나타났다. 전체적으로 결과는 Adversarial Attack의 일반적 특성과 일치하며, 신경망이 작지만 정교하게 설계된 섭동에도 취약함을 보여준다.